

CNN ve Ön Eğitimli Ağlar ile Alzheimer Hastalığının Sınıflandırılması

Özet

Alzheimer hastalığı, dünya çapında milyonlarca insanı etkileyen ve giderek artan bir sağlık sorunudur. Erken teşhis, hastalığın ilerlemesini yavaşlatmak ve tedaviyi optimize etmek için kritik öneme sahiptir. Bu çalışmada, derin öğrenme yöntemlerinin Alzheimer hastalığının erken teşhisinde kullanımı araştırılmıştır. Çalışmada, beyin MR görüntülerinden elde edilen veriler kullanılarak, konvolüsyonel sinir ağları (CNN'ler) ve ön eğitimli ağlar gibi derin öğrenme modelleri eğitilmiş ve test edilmiştir. Amaç, Alzheimer hastalığının ayırt edici özelliklerini belirlemek ve bu hastalığı sınıflandırmak için MR görüntülerinden elde edilen bilgileri kullanmaktır. Elde edilen sonuçlar, MyCNN Adam Yüksek modelinin %72 doğruluk oranıyla Alzheimer hastalığının sınıflandırılmasında yüksek doğruluk sağlayabildiğini göstermiştir. CNN ve ön eğitimli ağlar, hastalığı farklı evrelerinde doğru bir şekilde sınıflandırabilmiştir. Ayrıca, ön eğitimli ağların sıfırdan eğitilen modellere kıyasla daha az parametre ve daha hızlı eğitim süresi ile daha yüksek performans gösterdiği gözlemlenmiştir.

Bu çalışma, derin öğrenme tekniklerinin Alzheimer hastalığının erken teşhisinde önemli bir araç olabileceğini göstermektedir. Gelecekteki çalışmalar, daha geniş veri kümeleri ve daha gelişmiş derin öğrenme modelleri kullanılarak bu alandaki araştırmaları daha da ilerletmeyi hedeflemektedir.

Anahtar Kelimeler: Alzheimer Hastalığı, CNN, GoogleNet, MobilNet, Transfer Öğrenme, Derin Öğrenme

1. Giriş

Alzheimer hastalığı (AH), giderek ilerleyen ve bilişsel gerilemeye yol açan nörodejeneratif bir hastalıktır. Demansın en yaygın tipi olan AH, bireylerin ve toplumların yaşam kalitesini önemli ölçüde düşürmektedir. Son istatistiklere göre, 46,8 milyondan fazla kişi demans ile yaşarken, bu sayının 44 milyonu Alzheimer hastasıdır. Bu sayının 2050 yılına kadar 131,5 milyona yükselmesi beklenmektedir[1-2].

Hafif Bilişsel Yetmezlik (HBY), bilişsel olarak normal durumdan demansa geçişte görülen bir evredir ve %10 oranında Alzheimer hastalığına dönüşüm riski taşımaktadır [3]. Araştırmalar, HBY hastalarının yaklaşık %8-15'inin her yıl Alzheimer hastalığına yakalandığını, sağlıklı olduğu düşünülen bireylerin ise %1-2'sinin aynı süre içerisinde Alzheimer hastalığına yakalandığını göstermektedir [4-5]. Bu

bulgular erken teşhisin önemini vurgulamaktadır. İlginç bir şekilde, mevcut literatürdeki kanıtlar, takip sürelerine göre HBY evresinden normal duruma dönüş oranlarının klinik tabanlı çalışmalarda %4 ila %15, toplum tabanlı çalışmalarda ise %29 ila %55 arasında değiştiğini göstermektedir [6]. Bu bulgular, HBY evresinin hastalık sürecinin patolojik ilerlemesini geri döndürmek veya durdurmak için uygun bir müdahale penceresi aşaması olduğunu doğrulamaktadır.

Erken tanı ve müdahalenin kritik önem taşıdığı Alzheimer hastalığında, klinik belirtilerin ortaya çıkmasından yıllar önce hastalığa yönelik patolojik belirteçlerin araştırılması önem kazanmaktadır. Bu bağlamda, PET ve MR görüntüleme yöntemleri ile beyin spinal sıvısı (BSS) veya kan örneklerinin analizi gibi biyobelirteç analizi, hastalığın klinik başlangıcından önce tahmin edilmesine olanak sağlamaktadır [7-9] .

Teşhis ve sınıflamada yaygın olarak kullanılan MR görüntüleme, diğer yöntemlere göre birçok avantaja sahiptir. İyonlaştırıcı radyasyon içermemesi, non-invaziv olması, diğer yöntemlere göre daha düşük maliyetli olması ve çoğu sağlık ortamında daha kolay bulunması gibi avantajları sayesinde MR görüntüleme, Alzheimer hastalığı değerlendirmesinde önemli bir yer tutmaktadır. Ayrıca MR görüntüleme ile tek bir tarama seansında çok yönlü bilgi elde edilebilmesi de önemli bir avantaj olarak değerlendirilmektedir [10-12]. Klinik tarama bağlamında, geleneksel MR görüntüleme Alzheimer hastalığını normal bireylerden ayırt etmede nispeten başarılı sonuçlar gösterse de, HBY hastaları ile normal bireyler arasında ayırım yapmakta kısmen yetersiz kalmaktadır [13]. Dahası, HBY ve Alzheimer hastalığı hastalarının MR görüntüleri birbirine çok benzediği için geleneksel görüntüleme sınıflandırıcıları özellikle ileri yaş gruplarında bu iki evreyi etkin bir şekilde ayırt edememektedir [14]. Alzheimer hastalığının otomatik olarak teşhis edilmesinde istatistiksel ve Destek Vektör Makinesi (SVM) gibi makine öğrenmesi yöntemleri kullanılmaktadır [15]. Ancak son zamanlarda derin öğrenme teknikleri, özellikle Konvolüsyonel Sinir Ağları (CNN) ve seyrek oto-kodlayıcılar (sparse auto-encoders), SVM'e göre daha iyi performans göstermektedir [16].

Bu çalışmanın başlıca faydaları aşağıdaki gibi sıralanabilir:

- **Yüksek Doğruluk:** Derin öğrenme modelleri, Alzheimer hastalığının farklı evrelerini doğru bir şekilde sınıflandırmada yüksek doğruluk seviyeleri elde etmiştir. Bu durum, geleneksel tanı yöntemlerine kıyasla daha güvenilir ve tutarlı sonuçlar anlamına gelmektedir.
- **Erken Teşhis Olanakları:** Derin öğrenme modelleri, hastalığın erken evrelerinde bile teşhis konulmasını sağlayarak, hastanın tedaviye daha erken başlamasına ve hastalığın ilerlemesini geciktirmeye yardımcı olabilir.
- **Hızlı ve Ucuz Teşhis:** Derin öğrenme modelleri, MR görüntüleri gibi mevcut tıbbi görüntüleme yöntemlerini kullanarak hastalığı teşhis edebilir. Bu durum, invaziv prosedürlere ve pahalı testlere olan ihtiyacı ortadan kaldırarak teşhis sürecini hızlandırabilir ve maliyetleri düşürebilir.

- **Objektif ve Tutarlı Sonuçlar:** Derin öğrenme modelleri, insan hatası riskini azaltarak objektif ve tutarlı sonuçlar üretebilir. Bu durum, tanıdaki farklılıkları ve yanlış teşhisleri en aza indirmeye yardımcı olabilir.
- **Kişiselleştirilmiş Tıp:** Derin öğrenme modelleri, hastanın bireysel özelliklerine göre özelleştirilerek, daha kişiselleştirilmiş bir teşhis ve tedavi planı oluşturulmasına yardımcı olabilir.
- **Gelecekteki Araştırma Olanakları:** Bu çalışmanın bulguları, Alzheimer hastalığının teşhis ve tedavisinde derin öğrenmenin potansiyelini göstermektedir. Gelecekteki araştırmalar, daha geniş veri kümeleri ve daha gelişmiş derin öğrenme modelleri kullanılarak bu alandaki araştırmaları daha da ilerletmeyi hedeflemektedir.

2. İlgili Çalışmalar

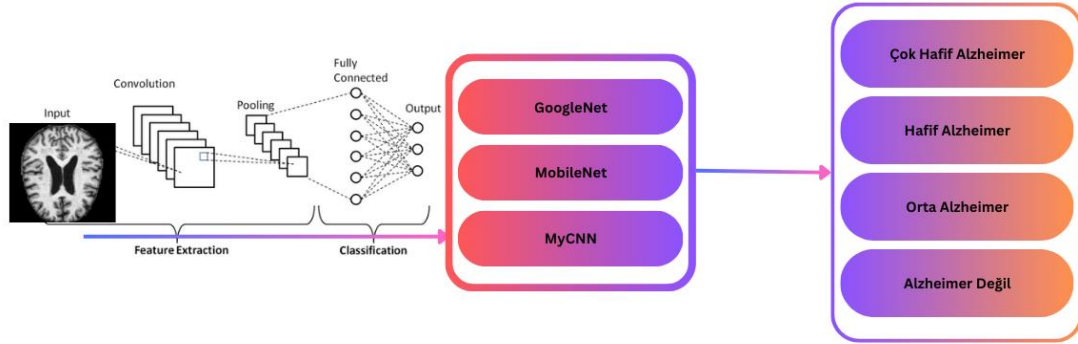
Alzheimer hastalığının erken teşhis edilmesinde klasik makine öğrenmesi modellerine göre CNN gibi derin öğrenme yöntemlerinin daha başarılı sonuçlar elde ettiği yapılan çalışmalarda görülmüştür. Alzheimer Hastalığı Nörogörüntüleme Girişimi (ADNI) veri setinin kullanıldığı bir çalışmada ilk olarak teşhis çalışmasında SVM kullanılarak %95.3 hassasiyet, %71.4 özgüllük ve %84.4 doğruluk elde edilmiştir. İkinci olarak CNN modeli kullanılmış ve %96'ya yakın yüksek bir doğruluk elde etmiştir (%96 hassasiyet, %98 özgüllük) [11]. Derin öğrenme yöntemleri arasındaki performans farkını gözlemlemek amacıyla 3D-CNN, 3D-CNN-destek vektör makinesi (SVM) ve iki boyutlu (2D)-CNN modelleri karşılaştırılmış, üçlü sınıflandırmada doğruluk sonuçları sırasıyla 2D-CNN, 3D-CNN ve 3D-CNN-SVM için 82.57 ± 7.35 , 89.76 ± 8.67 ve 95.74 ± 2.31 olmuştur. Bu çalışmada, 3D-CNN-SVM'nin MRI ile birlikte günümüzde kullanılan derin öğrenme yöntemlerine kıyasla daha iyi performans gösterdiği tespit edilmiştir [17]. Pradhan ve ark. yaptığı çalışmada görüntüleme, elektronik sağlık kaydı (EHR) ve tek nükleotid polimorfizmleri (SNP) veri setlerinin performansları doğruluk, hassasiyet, spesifisite ve çoklu alan (AUC) gibi metrikler kullanılarak karşılaştırmalı olarak değerlendirilmiş ve farklı hata türleri eğrilerin altına eklenerek gradyan hesaplanmıştır. Görüntüleme veri setinde % 95.45, EHR veri setinde %93.62, SNP veri setinde %99.2 doğruluk elde edilmiştir [15]. Başka bir çalışmada toplam 7635 adet HBY, normal kontrol ve Alzheimer hastalarının MR görüntülerini içeren veri seti CNN kullanılarak analiz edilmiştir. Veri seti %80 eğitim %20 test verisi olarak ayrılmıştır. Benzer çalışmalarla karşılaştırıldığında %99 gibi yüksek bir doğruluk elde edilmiştir. Ayrıca OASIS veri seti kullanılarak geleneksel makine öğrenmesi algoritmaları ile yapılan çalışmayla karşılaştırılmış ve tıbbi veriler gibi büyük veri kümeleriyle çalışılırken derin öğrenme yaklaşımlarının geleneksel makine öğrenmesi tekniklerinden daha iyi bir seçenek olabileceği sonucuna ulaşılmıştır [18]. İki boyutlu (2D) ve üç boyutlu (3D) konvolüsyonel sinir ağları (CNN) ve yinelemeli sinir ağları (RNN) dahil olmak üzere çeşitli derin öğrenme modellerinin karşılaştırıldığı bir çalışmada dizi bazlı kararların dilim bazlı kararlara göre %2 daha iyi doğrulukla sınıflandırdığı, ayrıca 3D voxel bazlı transfer öğrenme yönteminin diğer metotlara

göre % 96.88 doğruluk, %100 hassaslık ve 94.12 özgüllükle daha iyi sonuçlar verdiği saptanmıştır [19]. Büyük veri setlerinde başarılı sonuçlar veren transfer öğrenme ile Alzheimer hastalığının teşhisi amacıyla yapılan bir çalışmada Kaggle veri seti kullanılmıştır. Araştırmacılar çalışmada ADDTLA isimlendirdikleri modelde ham veriyi 227*227*3 boyuta çevirerek ön işlem uygulamışlar, transfer öğrenme için AlexNet kullanılmıştır. Çalışma sonunda 40 epokta çoklu sınıf problemleri için %91.7 doğruluk verdiği görülmüştür [12]. ADNI veri seti kullanılan başka bir çalışmada sınıflandırma yapılırken ayırt edici özelliklerin seçmenin zor olduğu vurgulanmıştır. Bu çalışmada CNN ve LeNet-5 mimarisi kullanılarak %98,84 doğruluk oranına ulaşılmıştır [20]. Acharya ve ark. Kaggle veri setini transfer öğrenme yöntemleri ile derin öğrenme modelleri ile analiz etmişlerdir. Çalışmada VGG16, ResNet-50 ve AlexNet gibi önceden eğitilmiş derin öğrenme modelleri transfer öğrenme yaklaşımıyla konvolüsyonel sinir ağlarına entegre edilmiş ve %95,70 doğruluk oranı ile transfer öğrenmenin Alzheimer hastalığının teşhisinde etkin olduğu göstermişlerdir [21].

3. Materyal ve Yöntem

Bu çalışmada, hibrit modellerin üstünlüğünü göstermek için MobileNet, GoogleNet ve MyCNN ağları ayrılarak birlikte çalıştırılmıştır.


Uygulanan çalışmanın işlem adımlarını içeren blok şeması Şekil 2'de gösterilmiştir.



Şekil 2.1. Önerilen modelin blok diyagramı

3.1 GoogleNet Ağ Yapısı

Şekil 3'te GoogleNet 'in mimari yapısı basit bir şekilde anlatılmıştır.



Şekil 2.2. GoogleNet Ağ Yapısı

2014 yılında Google tarafından tanıtılan GoogleNet, görüntü sınıflandırma alanında önemli bir kilometre taşı olmuştur. Inception modülü ve yardımcı sınıflandırıcılar gibi yenilikçi mimari özellikler sayesinde ImageNet Large Scale Visual Recognition Challenge gibi önde gelen yarışmalarda %90.5'lik doğruluk oranı ile üstün performans sergilemiştir. Yüksek doğruluk oranıyla birlikte düşük hesaplama maliyeti, GoogleNet'i geniş bir uygulama yelpazesinde tercih edilen bir model haline getirmiştir.

GoogleNet'in Avantajları:

GoogleNet'in başarısının temelinde, "Inception" olarak adlandırılan yenilikçi bir mimari modül yer almaktadır. Inception modülü, farklı boyutlarda filtreleri paralel olarak uygulayarak derinlik ve genişlik boyutları arasında denge sağlamaktadır. Bu modül, ağın parametre sayısını azaltırken hesaplama yoğunluğunu artırarak daha etkili bir öğrenme gerçekleştirmektedir. GoogleNet'in toplam parametre sayısı oldukça düşüktür (yaklaşık 4 milyon), bu da modelin eğitim ve kullanım süreçlerini hızlandırmaktadır. GoogleNet'in diğer önemli bir özelliği ise "yardımcı sınıflandırıcılar" olarak bilinen bileşenlerdir. Bu bileşenler, ağın ara katmanlarında yer alır ve her bir katmanda görüntünün sınıflandırılmasını yaparak ağın derinlik boyutunu artırırken aşırı uyum problemiyle başa çıkmaya yardımcı olur.

Kullanım Alanları:

GoogleNet, görüntü sınıflandırma, nesne tespiti ve görüntü segmentasyonu gibi birçok görevde kullanılabilir. Özellikle tıp, mühendislik, perakende ve güvenlik gibi alanlarda önemli bir rol oynamaktadır.

GoogleNet'in Dezavantajları:

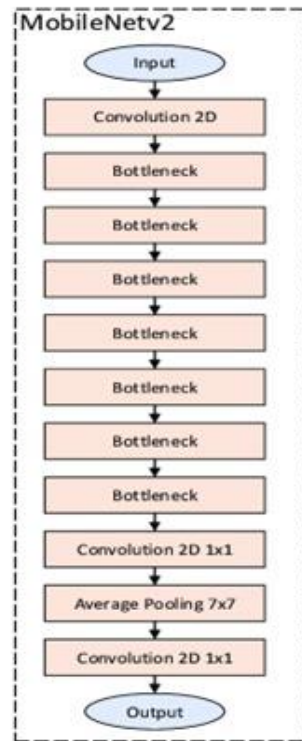
Karmaşıklık: GoogleNet'in mimarisi oldukça karmaşıktır ve bu da modelin eğitimi ve kullanımını zorlaştırabilir.

Büyük Veri Kümesi Gereksinimi: GoogleNet'in yüksek performans gösterebilmesi için büyük veri kümeleri ile eğitilmesi gerekir.

Hesaplama Maliyeti: GoogleNet, diğer derin öğrenme modellerine kıyasla daha yüksek hesaplama maliyetine sahip olabilir. [22].

3.2 MobileNetV2 Ağ Yapısı

Şekil 3'te MobileNetV2 'nin mimari yapısı basit bir şekilde anlatılmıştır.



Şekil 3.3. MobileNet Ağ Yapısı

MobileNetV2, 2017 yılında Google tarafından mobil ve yerleşik görüntüleme uygulamaları için özel olarak tasarlanmış hafif bir evrimsel sinir ağı (CNN) mimarisidir. Google araştırmacıları tarafından orijinal MobileNet modelinin bir geliştirmesi olarak geliştirilmiştir. GoogleNet'in temel prensiplerini kullanarak, MobileNet modelinin karmaşıklığı ve parametre sayısı önemli ölçüde azaltılmıştır. Bu sayede MobileNetV2, mobil cihazlar gibi işlem gücü sınırlı cihazlarda bile çalışabilir [23].

MobileNetV2 mimarisi, derinlemesine ayrılabilir evrişim, ters kalıntılar, dar boğaz tasarımı, doğrusal dar boğazlar ve sıkıştırma ve uyarma (SE) blokları gibi çeşitli katmanlardan oluşur. Bu bileşenler, modelin

karmaşık özellikleri yakalama yeteneğini korurken model için gerekli parametre ve hesaplama sayısını azaltmak için birlikte çalışır.

- **Derinlemesine Ayrılabilir Evrişim((Depthwise Separable Convolution) :** Bu teknik, standart evrişimi iki ayrı işlemeye ayırarak kıvrımların hesaplama maliyetini önemli ölçüde azaltır: derinlik kıvrımı ve nokta kıvrımı. Bu ayırım, gerekli hesaplama sayısını önemli ölçüde azaltarak modeli daha verimli hale getirir.
- **Ters Kalıntılar (Inverted Residuals):** Ters kalıntılar, modelin doğruluğunu artırmaya yardımcı olan MobileNetV2'nin temel bir bileşenidir. Derin ayrılabilir evrişim uygulamadan önce kanal sayısını genişleten bir dar boğaz yapısı sunarlar. Bu genişleme, modelin daha karmaşık özellikleri yakalamasına ve temsil gücünü geliştirmesine olanak tanır.
- **Dar Boğaz Tasarımı (Bottleneck Design):** MobileNetV2, derinlemesine ayrılabilir evrişim uygulanmadan önce 1x1 kıvrımlar kullanarak kanal sayısını azaltarak hesaplama maliyetini daha da düşürür. Bu tasarım seçimi, model boyutu ve doğruluk arasında iyi bir denge kurmaya yardımcı olur.
- **Doğrusal Dar Boğazlar (Linear Bottlenecks):** Doğrusal dar boğazlar, dar boğaz işlemi sırasında bilgi kaybı sorununu çözmek için MobileNetV2'ye dahil edilir. Doğrusal etkinleştirmeleri doğrusal olmayan etkinleştirmeler yerine kullanarak model daha fazla bilgi tutar ve ince ayrıntıları yakalama yeteneğini geliştirir.
- **Sıkıştırma ve Uyarma (SE) Blokları (Squeeze-and-Excitation (SE) Blocks) :** Bu bloklar, MobileNetV2'nin özellik gösterim yeteneklerini geliştirmek için eklenir. Kanal başına özellik tepkilerini uyarlamalı olarak yeniden kalibre ederek, modelin daha bilgilendirici özelliklere odaklanmasını ve daha az alakalı olanları bastırmasını sağlar.

MobileNetV2'nin eğitim adımları ise aşağıdaki gibidir:

- **Veri Hazırlama (Data Preparation):** MobileNetV2'yi eğitmeden önce verilerin uygun şekilde hazırlanması önemlidir. Bu, görüntüleri ön işlemeyi, veri kümesini eğitim ve doğrulama kümelerine ayırmayı ve modelin genelleme yeteneğini geliştirmek için veri artırma tekniklerini uygulamayı içerir.
- **Transfer Öğrenme (Transfer Learning):** Bu, MobileNetV2 ile kullanılacak ve büyük ölçekli veri setlerinde önceden eğitilmiş modellerin gücünden yararlanmaya yarayan popüler bir tekniktir. Model önceden eğitilmiş ağırlıklarla başlatılarak eğitim süreci hızlandırılabilir ve model kaynak veri setinden öğrenilen bilgiden faydalanabilir.
- **İnce Ayar (Fine-Tuning):** Bu aşama, önceden eğitilmiş ağırlıkları belirli katmanlar için sabit

tutarken MobileNetV2'yi hedef veri seti üzerinde eğitmeyi içerir. Bu, modelin hedef veri setinin benzersiz özelliklerine uyum sağlamasına olanak tanırırken kaynak veri setinden edinilen bilgiyi korur.

- **Hiper parametre Ayarlama(Hyperparameter Tuning):** MobileNetV2'nin performansını optimize etmek, özenli hiperparametre ayarına bağlıdır. Öğrenme oranı, toplu boyut ve düzenlileştirme teknikleri gibi parametreler, en iyi sonuçları elde etmek için dikkatlice seçilmelidir. Grid arama veya random arama gibi teknikler, ideal hiper parametre kombinasyonunu bulmak için kullanılabilir.

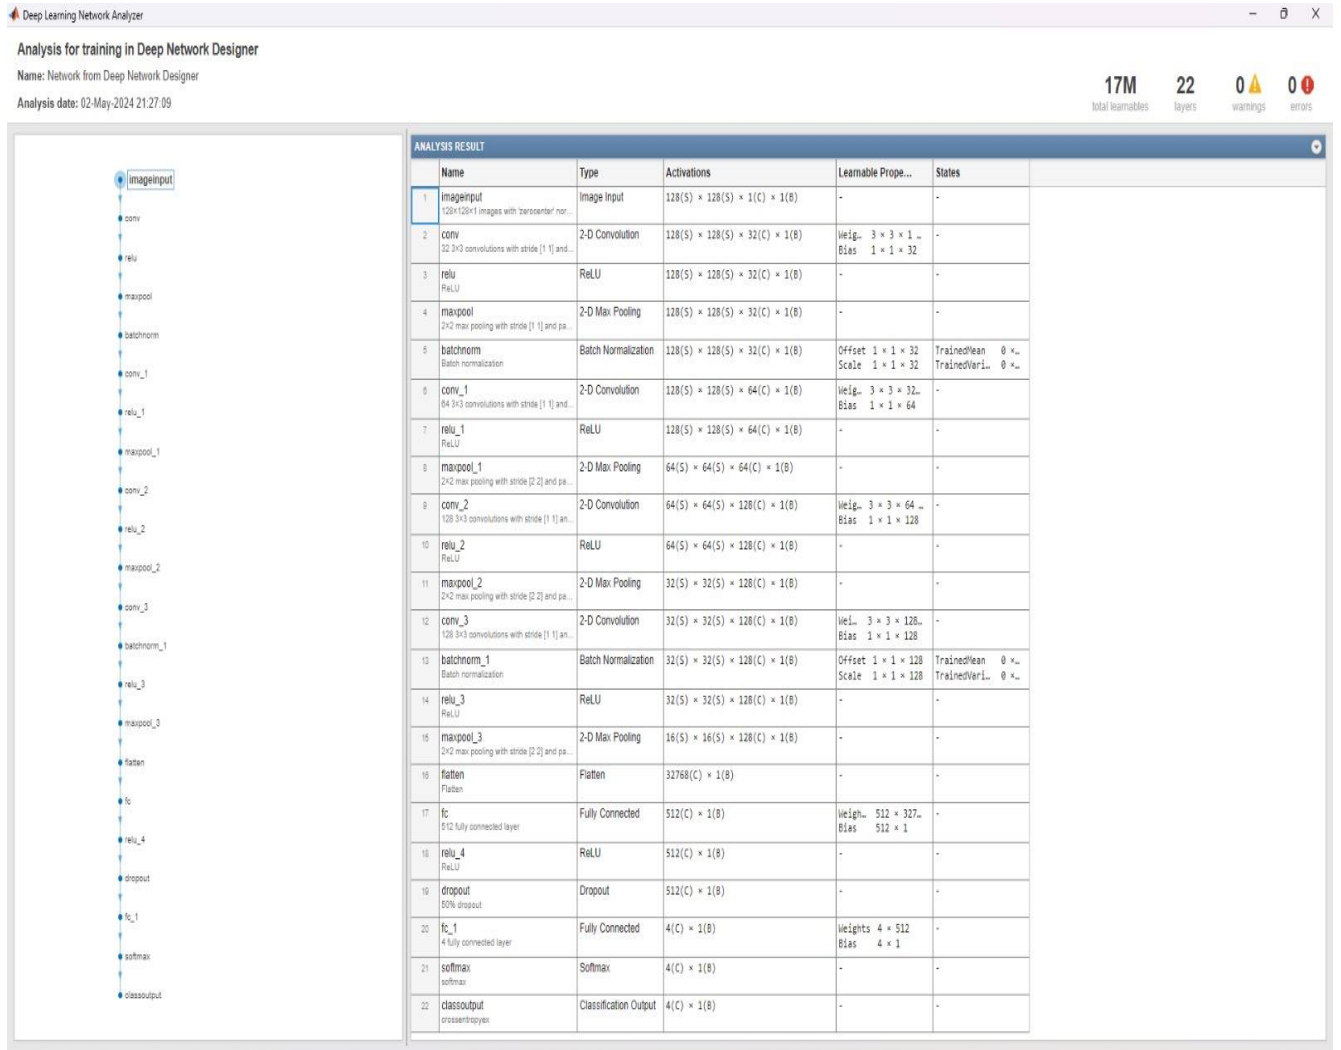
MobileNetV2 performansı değerlendirilirken doğruluk, hassaslık, geri çağırma, F1 puanı ve karışıklık matrisi gibi görüntü sınıflandırma değerlendirme ölçütleri ile doğruluk, model boyutu ve kıyaslama veri setlerinde çıkarım süresi gibi diğer modellerle karşılaştırma ölçütleri kullanılır. Bu ölçütler MobileNetV2'nin güçlü ve zayıf yönleri hakkında kapsamlı bir anlayış sağlar.

MobileNetV2, nesne tanıma, yüz tanıma ve sahne anlama gibi çeşitli gerçek dünya uygulamalarında başarıyla uygulanmıştır. MobileNetV2'nin bu alanlardaki performansını ve pratikliğini inceleyen vaka çalışmaları, potansiyel kullanım örnekleri hakkında değerli bilgiler sunabilir [24-27].

Sonuç olarak MobileNetV2, görüntü sınıflandırma görevleri için güçlü ve hafif bir model olarak öne çıkmaktadır. Verimli mimarisi ve yüksek doğruluğu koruma yeteneği onu sınırlı hesaplama kaynaklarına sahip cihazlara dağıtım için ideal bir seçim haline getirmektedir.

3.3 MyCNN Ağ Yapısı

Deep Learning With Python – François Chollet kitabında bulunan bu sinir ağı modelini matlab ortamına geçirdik ve eğitimimiz için kullandık. Sıklıkla kullanılan hazır eğitilmiş ağların yanı sıra harici bir ağ kullanarak karşılaştırma yapmak istedik. Ağın mimarisi Şekil 3.4'te görünmektedir.



Şekil 3.4. MyCNN Ağ Yapısı

3.4 Veri Seti

Bu çalışmada Kaggle'dan bize verilen <https://www.kaggle.com/datasets/tourist55/alzheimers-dataset-4-class-of-images?resource=download> Alzheimer Veri Seti kullanılmıştır. Veri seti çok hafif Alzheimer, hafif Alzheimer, orta Alzheimer ve Alzheimer olmayan olmak üzere 4 gruptan oluşan 6400 adet MR görüntüsü içermektedir.

Paylaşılan veri seti %65 eğitim, %20 validasyon ve %15 test olmak üzere üçe bölünmüştür.

Tablo 1. Verinin Sınıflara Göre Dağılımı

	Çok Hafif Alzheimer	Hafif Alzheimer	Orta Alzheimer	Alzheimer Değil
Eğitim	1431	568	34	2075

Doğrulama	361	149	18	485
Test	448	179	12	640
Toplam	2240	896	64	3200

3.5 Performans Değerlendirme Kriteri

Doğruluk sınıflandırma algoritmalarının performansını ölçmek için kullanılan ana ölçütlerden biridir.

Doğruluk, doğru tahmin oranının oranını gösterir. Şu şekilde hesaplanır:

$$Accuracy = (TN + TP) / (TP + FP + TN + FN)$$

3.6 Eğitim Ayarları ve Hiper parametreler

Eğitimlerimizde karşılaştırmak üzere iki eğitim düzeneği kullandık; yüksek ayarlar ve düşük ayarlar. Yüksek ayar ile eğittiğimiz modeller daha doğru sonuç verirken eğitim süreleri daha uzun oldu. Düşük ayar ile eğittiğimiz modellerde ise doğruluk değerleri bir model haricinde karşılaştırılamayacak derecede düşüktü. Buna rağmen daha kısa eğitim süreleri sağlandı.

Tablo 3.2. Eğitimde Kullanılan Parametreler

Parametreler	Değerler	
Epoch sayısı	15	
Optimizasyon algoritmaları	Adam – Sgdm – Rmsprop	
Sınıflandırma katmanı aktivasyon fonksiyonu	Softmax	
Sınıf sayısı	4	
Eğitim – Validasyon – Test verisi oranı	%65 - %20 - %15	
Değişken Parametreler	Yüksek	Düşük
Öğrenme adım sayısı	0.0001	0.01

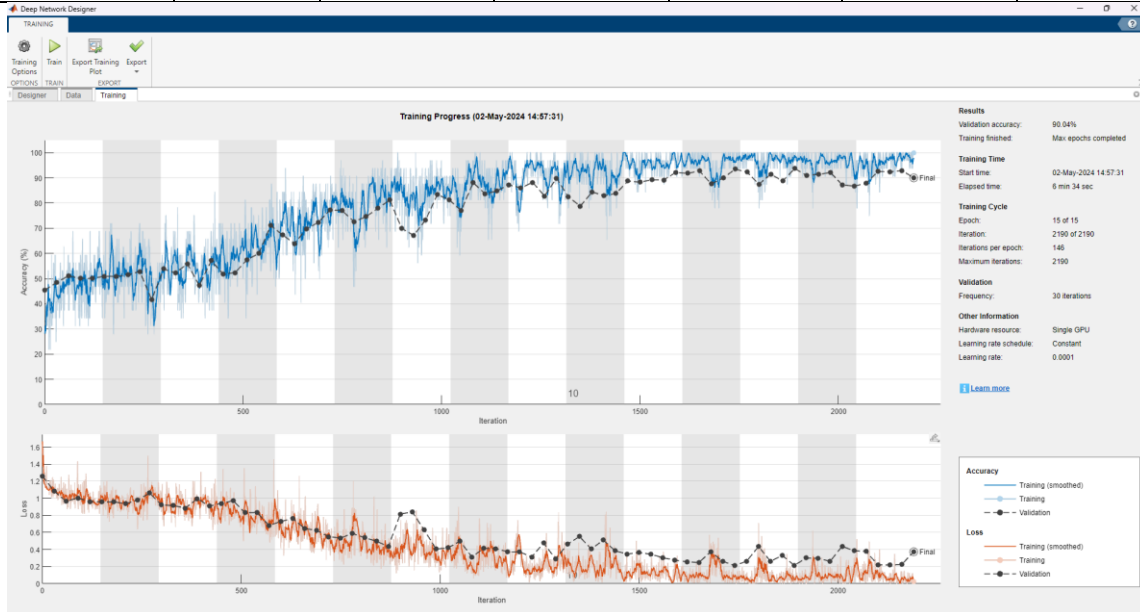
Yığın boyutu	32	16
--------------	----	----

4. Sonuçlar

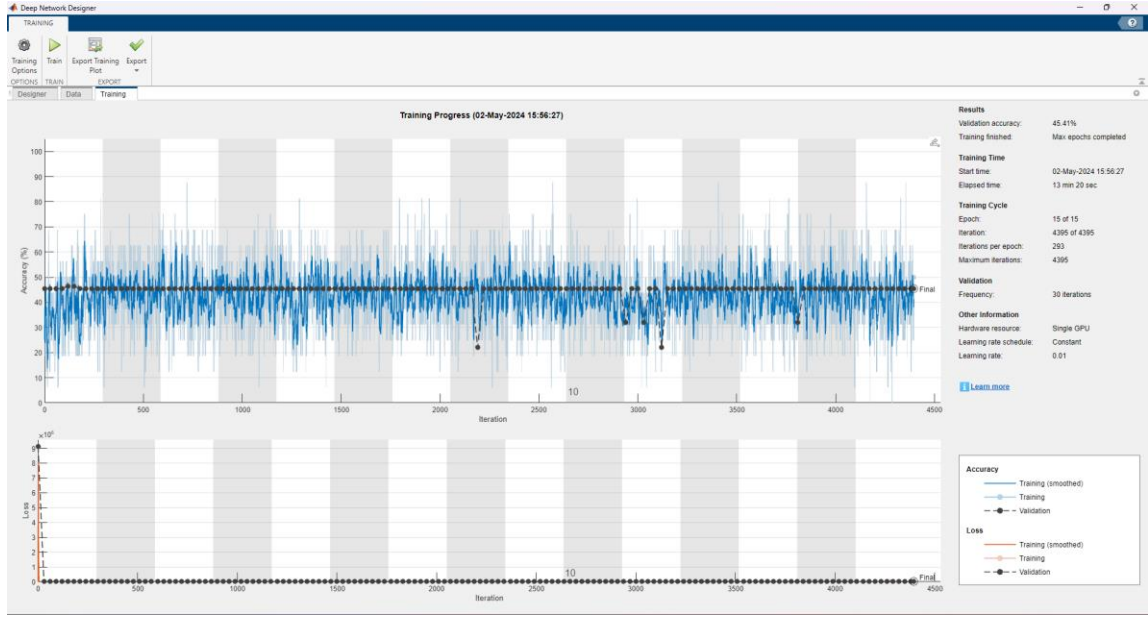
Model için Adam, Sgdm ve Rmsprop Optimizasyon Algoritmaları kullanılmıştır. Düşük ve Yüksek hassasiyet olmak üzere iki ayar kullandık. Düşük ayar olarak Öğrenme oranı 0.01, yığın boyutu 16, Yüksek ayarın özellikleri ise Öğrenme oranı 0.0001, yığın boyutu 32 olarak iki ayar olmak üzere kullandık. 15 adımda çalıştırılan dört modelin doğruluk değerleri Tablo 4.3'de gösterilmiştir.

Tablo 4.3. Ağların Çeşitli Ayarlarla Eğitim Sonucundaki Doğruluk Yüzdeleri

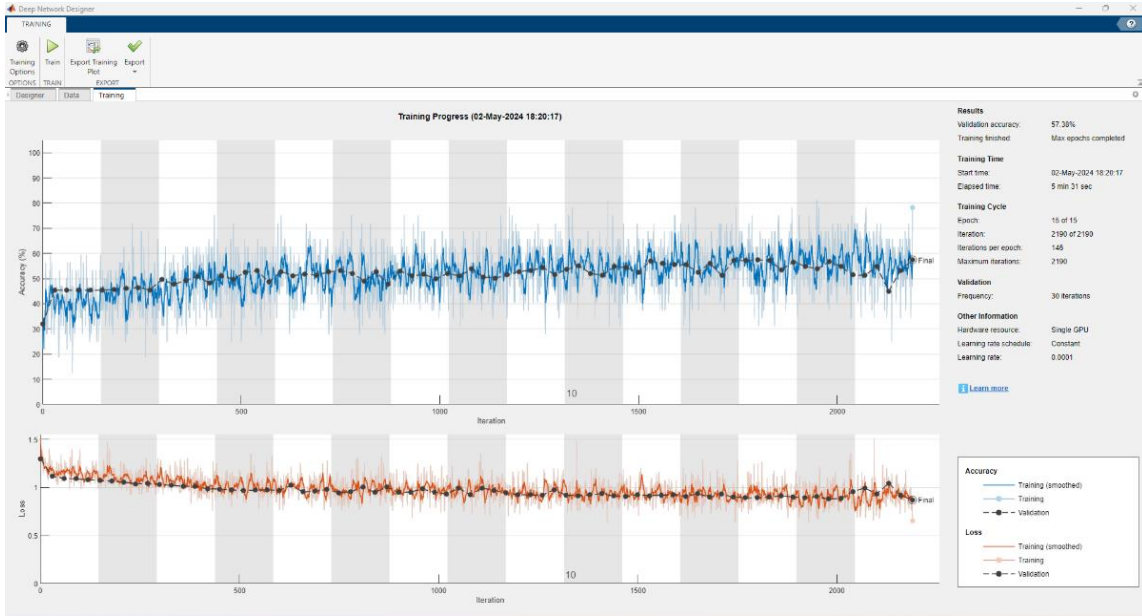
Ağlar	Optimizasyon Ayarları					
	Adam Yüksek	Adam Düşük	Rmsprop Yüksek	Rmsprop Düşük	SGDM Yüksek	SGDM Düşük
GoogleNet	%90.04	%45.41	%89.69	%45.41	%57.38	%71.18
MobileNetv2	%69.43	%83.93	%55.36	%61.11	%58.23	%95.93
MyCNN	%98.25	%45.41	%95.37	%45.41	%95.46	%45.41



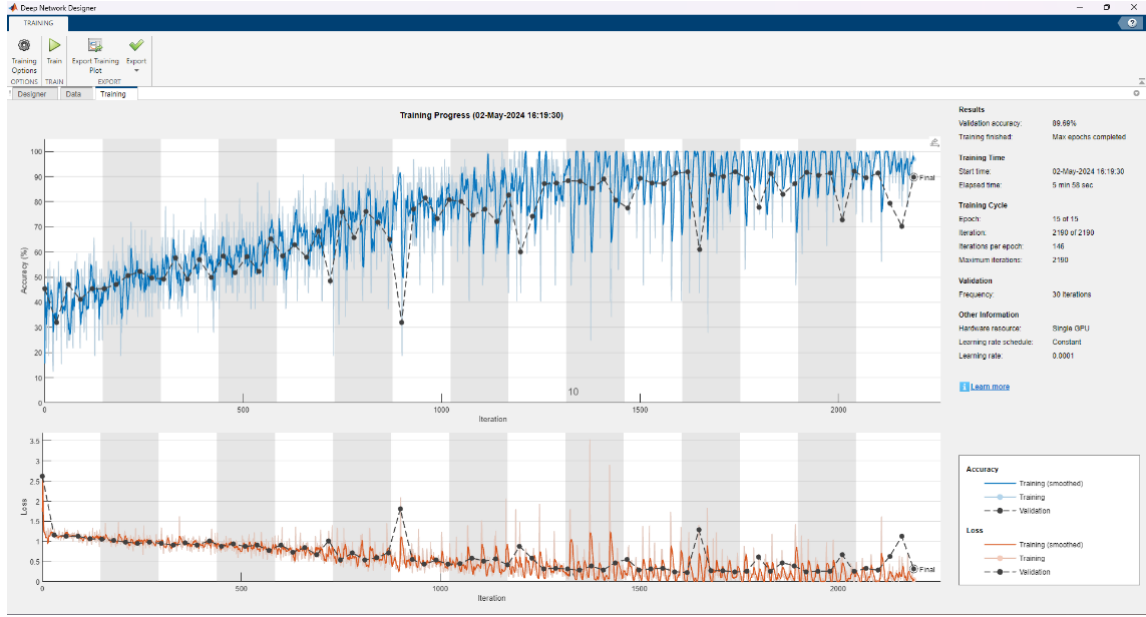
Şekil 4.5: GoogleNet Adam Yüksek Ayar Eğitim Süreci



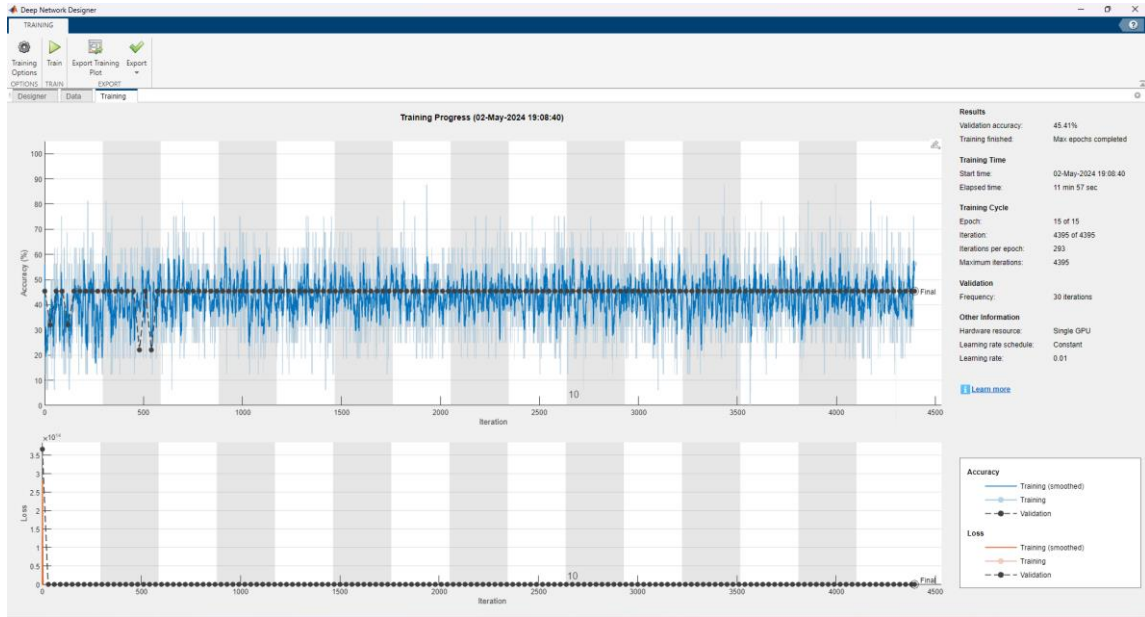
Şekil 4.6: GoogleNet Adam Düşük Ayar Eğitim Süreci



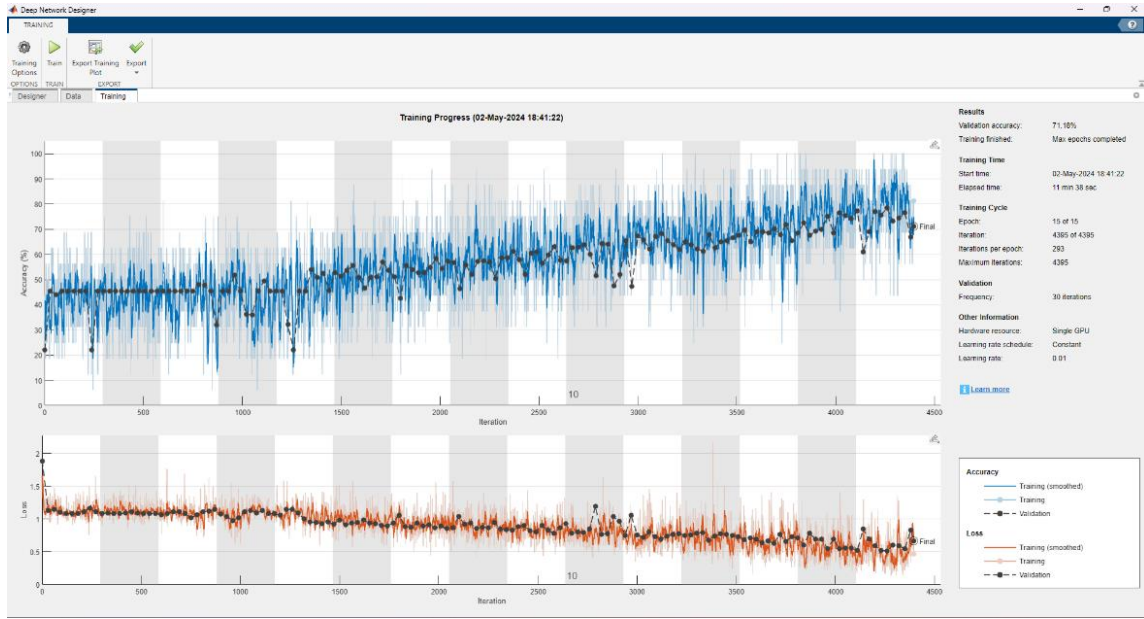
Şekil 4.7: GoogleNet Rmsprop Yüksek Ayar Eğitim Süreci



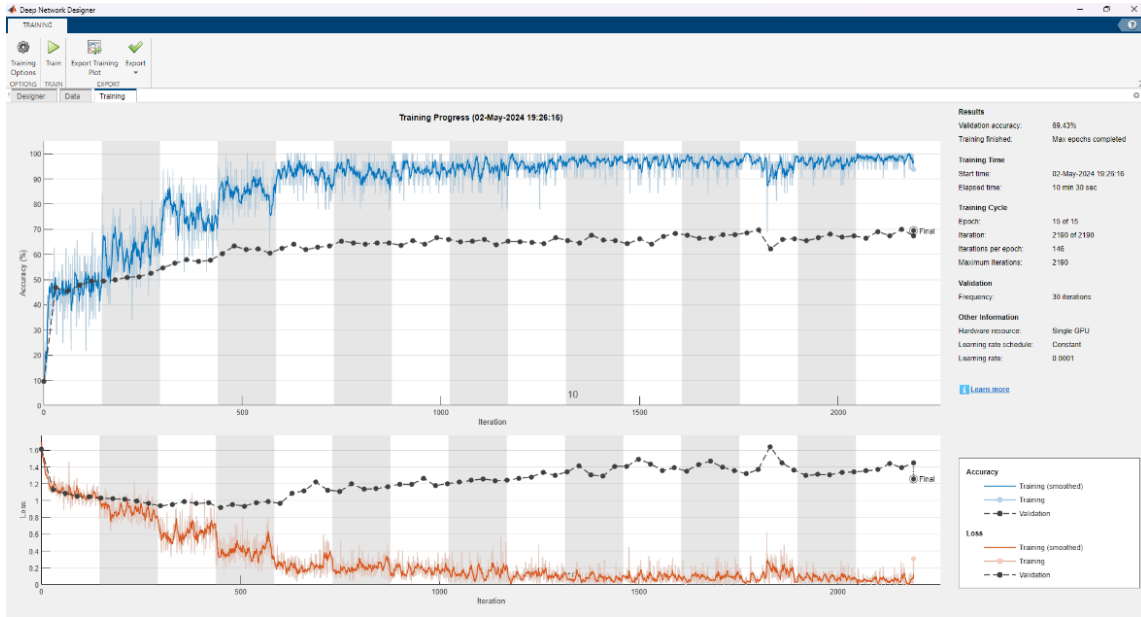
Şekil 4.8: GoogleNet Rmsprop Düşük Ayar Eğitim Süreci



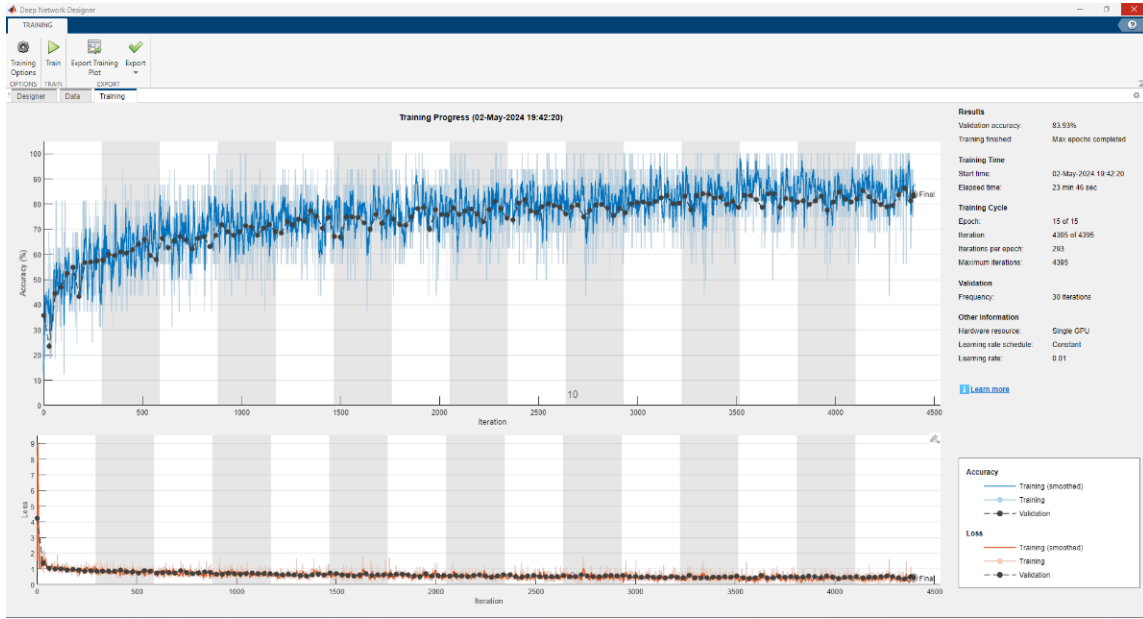
Şekil 4.9: GoogleNet Sgd Yüksek Ayar Eğitim Süreci



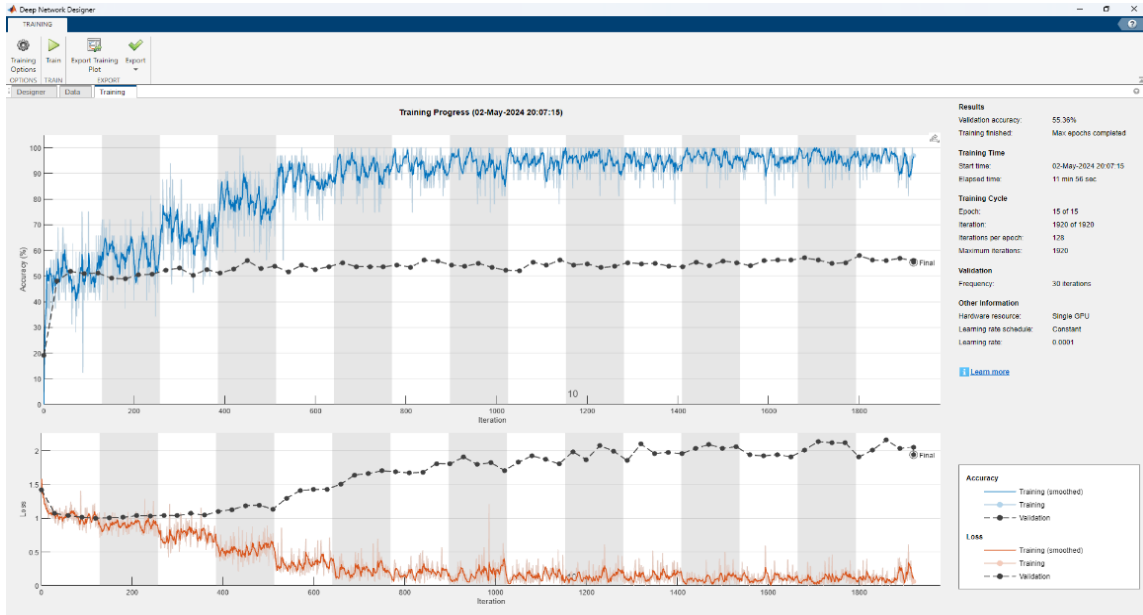
Şekil 4.10: GoogleNet Sgdm Düşük Ayar Eğitim Süreci



Şekil 4.11: MobileNet Adam Yüksek Ayar Eğitim Süreci



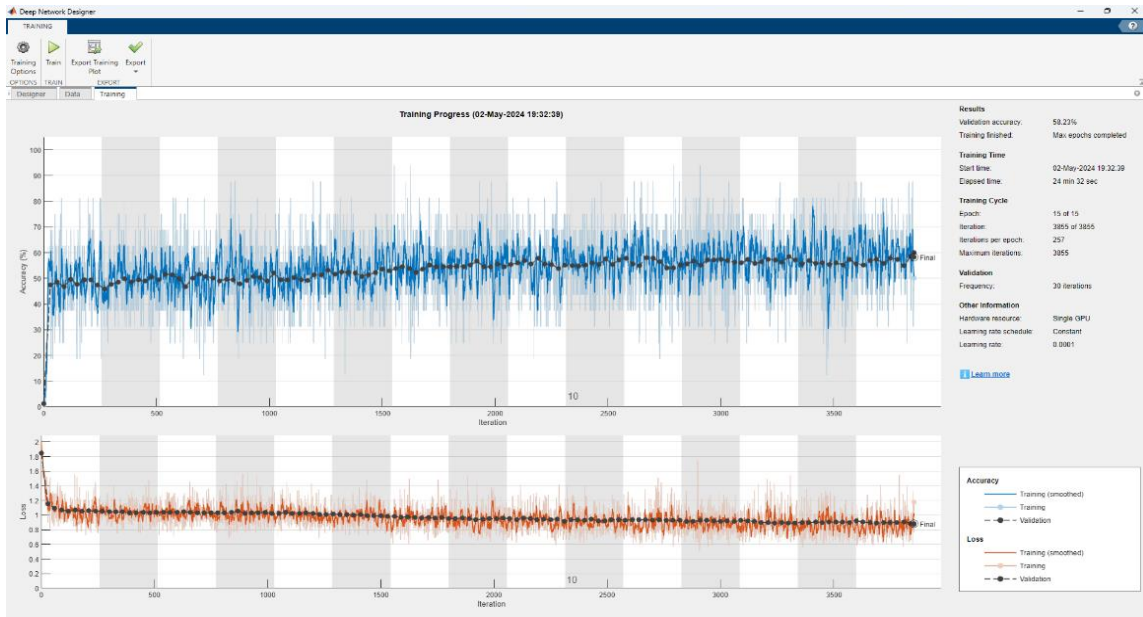
Şekil 4.12: MobileNet Adam Düşük Ayar Eğitim Süreci



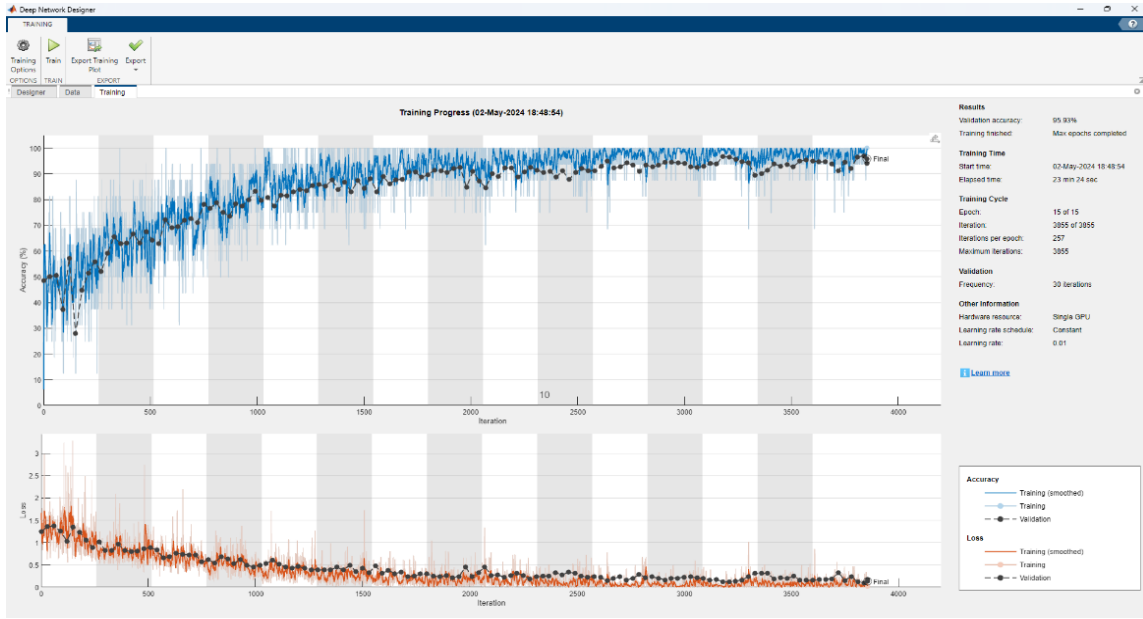
Şekil 4.13: MobileNet Rmsprop Yüksek Ayar Eğitim Süreci



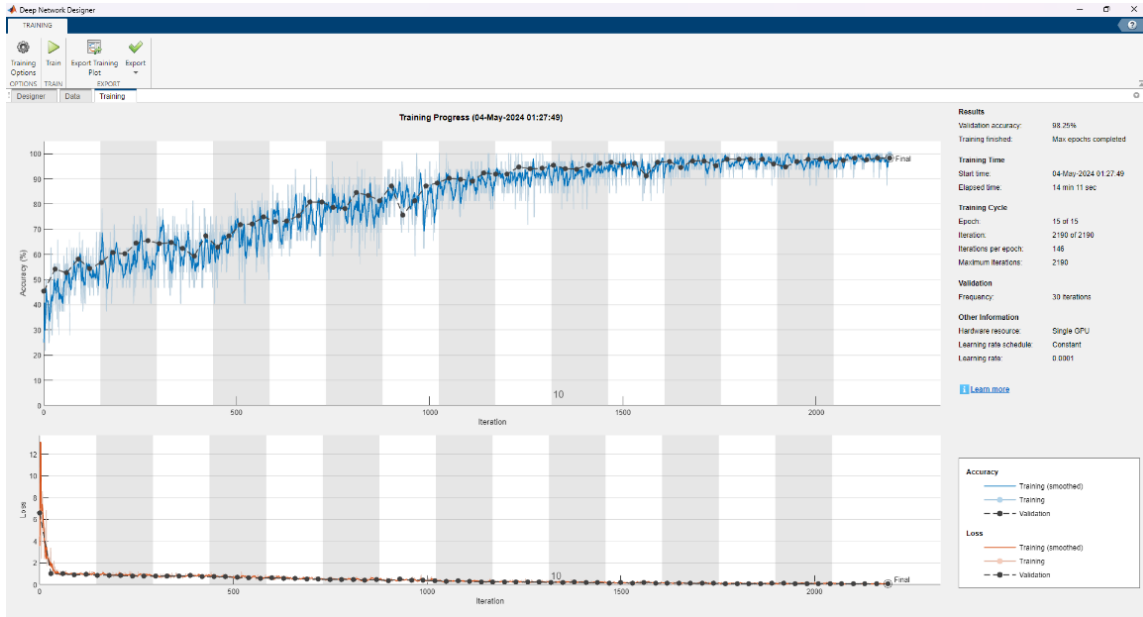
Şekil 4.14: MobileNet Rmsprop Düşük Ayar Eğitim Süreci



Şekil 4.15: MobileNet Sgdm Yüksek Ayar Eğitim Süreci




Şekil 4.16: MobileNet Sgdm Düşük Ayar Eğitim Süreci



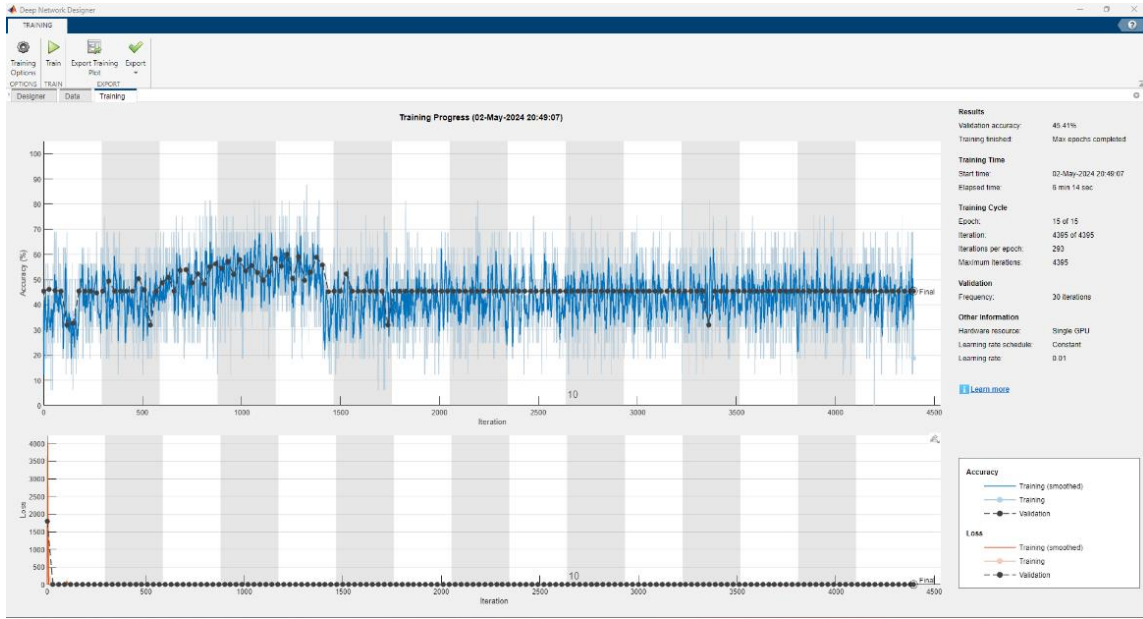
Şekil 4.17: MyCNN Adam Yüksek Ayar Eğitim Süreci



Şekil 4.18: MyCNN Adam Düşük Ayar Eğitim Süreci



Şekil 4.19: MyCNN Rmsprop Yüksek Ayar Eğitim Süreci



Şekil 4.20: MyCNN Rmsprop Düşük Ayar Eğitim Süreci



Şekil 4.21: MyCNN Sgdm Yüksek Ayar Eğitim Süreci



Şekil 4.22: MyCNN Sgdm Düşük Ayar Eğitim Süreci

Tablo 4, her üç model için doğruluk (accuracy) değerlerini göstermektedir. Sonuçlar karşılaştırıldığında MyCNN Adam Yüksek modelinin daha başarılı sonuç verdiği görülmektedir.

Tablo 4.4. Performans Tablosu

Model			Accuracy
GoogleNet	Adam	Yüksek	0.6208
		Düşük	0.50039
	Sgdm	Yüksek	0.56138
		Düşük	0.56294
	Rmsprop	Yüksek	0.59265
		Düşük	0.50039
MobileNetv2	Adam	Yüksek	0.4871
		Düşük	0.57858
	Sgdm	Yüksek	0.52385
		Düşük	0.5731
	Rmsprop	Yüksek	0.48163
		Düşük	0.57701
MyCNN	Adam	Yüksek	0.72166
		Düşük	0.50039
	Sgdm	Yüksek	0.68569
		Düşük	0.50039
	Rmsprop	Yüksek	0.67084
		Düşük	0.50039

Aşağıda eğitilmiş tüm modellerin test verileriyle elde edilen karşılaştırma matrisleri bulunmaktadır.

Konfüzyon Matrisi				
Gerçek Etiketler	MildDemented	ModerateDemented	NonDemented	VeryMildDemented
	64		8	107
	4			8
	4		383	253
	16		85	347
Tahmin Edilen Etiketler				

Konfüzyon Matrisi				
Gerçek Etiketler	MildDemented	ModerateDemented	NonDemented	VeryMildDemented
			179	
			12	
			640	
			448	
Tahmin Edilen Etiketler				

Şekil 4.23: Googlenet Adam Yüksek Ayarlı Eğitim Karşılaştırma Matrisi

Şekil 4.24 Googlenet Adam Düşük Ayarlı Eğitim Karşılaştırma Matrisi

Konfüzyon Matrisi				
Gerçek Etiketler	MildDemented	ModerateDemented	NonDemented	VeryMildDemented
	58		23	98
	4		2	6
	24		440	176
	38		190	220
Tahmin Edilen Etiketler				

Konfüzyon Matrisi				
Gerçek Etiketler	MildDemented	ModerateDemented	NonDemented	VeryMildDemented
	77		7	95
	5			7
	38		424	178
	79		150	219
Tahmin Edilen Etiketler				

Şekil 4.25: Googlenet Sgdm Yüksek Ayarlı Eğitim Karşılaştırma Matrisi

Şekil 4.26: Googlenet Sgdm Düşük Ayarlı Eğitim Karşılaştırma Matrisi

Konfüzyon Matrisi				
Gerçek Etiketler	MildDemented	ModerateDemented	NonDemented	VeryMildDemented
	86		9	84
	1		2	9
	6		316	318
	42		50	356
Tahmin Edilen Etiketler				

Konfüzyon Matrisi				
Gerçek Etiketler	MildDemented	ModerateDemented	NonDemented	VeryMildDemented
			179	
			12	
			640	
			448	
Tahmin Edilen Etiketler				

Şekil 4.27: Googlenet Rmsprop Yüksek Ayarlı Eğitim Karşılaştırma Matrisi

Şekil 4.28: Googlenet Rmsprop Düşük Ayarlı Eğitim Karşılaştırma Matrisi

Konfüzyon Matrisi					
Gerçek Etiketler	MildDemented	26	1	83	69
	ModerateDemented	2		4	6
	NonDemented	45	1	431	163
	VeryMildDemented	40	2	240	166
		MildDemented	ModerateDemented	NonDemented	VeryMildDemented
		Tahmin Edilen Etiketler			

Konfüzyon Matrisi					
Gerçek Etiketler	MildDemented				
	13		80	86	
	ModerateDemented		5	7	
	NonDemented	4	480	156	
VeryMildDemented	12		189	247	
		MildDemented	ModerateDemented	NonDemented	VeryMildDemented
		Tahmin Edilen Etiketler			

Şekil 4.29: MobileNet Adam Yüksek Ayarlı Eğitim Karşılaştırma Matrisi Şekil 4.30: MobileNet Adam Düşük Ayarlı Eğitim Karşılaştırma Matrisi

Konfüzyon Matrisi					
Gerçek Etiketler	MildDemented	7		81	91
	ModerateDemented	2		7	3
	NonDemented	4		516	120
	VeryMildDemented	4		297	147
		MildDemented	ModerateDemented	NonDemented	VeryMildDemented
		Tahmin Edilen Etiketler			

Konfüzyon Matrisi					
Gerçek Etiketler	MildDemented	53		69	57
	ModerateDemented	2	2	4	4
	NonDemented	31	1	461	147
	VeryMildDemented	35	3	193	217
		MildDemented	ModerateDemented	NonDemented	VeryMildDemented
		Tahmin Edilen Etiketler			

Şekil 4.31: MobileNet Sgdm Yüksek Ayarlı Eğitim Karşılaştırma Matrisi Şekil 4.32: MobileNet Sgdm Düşük Ayarlı Eğitim Karşılaştırma Matrisi

Konfüzyon Matrisi					
Gerçek Etiketler	MildDemented	18	1	86	74
	ModerateDemented	1		7	4
	NonDemented	18		439	183
	VeryMildDemented	33	1	255	159
		MildDemented	ModerateDemented	NonDemented	VeryMildDemented
		Tahmin Edilen Etiketler			

Konfüzyon Matrisi					
Gerçek Etiketler	MildDemented		41	138	
	ModerateDemented		7	5	
	NonDemented		515	125	
	VeryMildDemented		225	223	
		MildDemented	ModerateDemented	NonDemented	VeryMildDemented
		Tahmin Edilen Etiketler			

Şekil 4.33: MobileNet Rmsprop Yüksek Ayarlı Eğitim Karşılaştırma Matrisi Şekil 4.34: AlexNet Rmsprop Düşük Ayarlı Eğitim Karşılaştırma Matrisi

		Konfüzyon Matrisi			
Gerçek Etiketler	MildDemented	76		45	58
	ModerateDemented		2	2	8
	NonDemented	13		520	107
	VeryMildDemented	8		115	325
		MildDemented	ModerateDemented	NonDemented	VeryMildDemented
		Tahmin Edilen Etiketler			

		Konfüzyon Matrisi			
Gerçek Etiketler	MildDemented			179	
	ModerateDemented			12	
	NonDemented			640	
	VeryMildDemented			448	
		MildDemented	ModerateDemented	NonDemented	VeryMildDemented
		Tahmin Edilen Etiketler			

Şekil 4.35: MyCNN Adam Yüksek Ayarlı Eğitim Karşılaştırma Matrisi

Şekil 4.36: MyCNN Adam Düşük Ayarlı Eğitim Karşılaştırma Matrisi

		Konfüzyon Matrisi			
Gerçek Etiketler	MildDemented	71		71	37
	ModerateDemented	2		3	7
	NonDemented	15		572	53
	VeryMildDemented	21		193	234
		MildDemented	ModerateDemented	NonDemented	VeryMildDemented
		Tahmin Edilen Etiketler			

		Konfüzyon Matrisi			
Gerçek Etiketler	MildDemented			179	
	ModerateDemented			12	
	NonDemented			640	
	VeryMildDemented			448	
		MildDemented	ModerateDemented	NonDemented	VeryMildDemented
		Tahmin Edilen Etiketler			

Şekil 4.37: MyCNN Sgdm Yüksek Ayarlı Eğitim Karşılaştırma Matrisi

Şekil 4.38: MyCNN Sgdm Düşük Ayarlı Eğitim Karşılaştırma Matrisi

		Konfüzyon Matrisi			
Gerçek Etiketler	MildDemented	46		83	50
	ModerateDemented		1	6	5
	NonDemented	4		575	61
	VeryMildDemented	4		208	236
		MildDemented	ModerateDemented	NonDemented	VeryMildDemented
		Tahmin Edilen Etiketler			

		Konfüzyon Matrisi			
Gerçek Etiketler	MildDemented			179	
	ModerateDemented			12	
	NonDemented			640	
	VeryMildDemented			448	
		MildDemented	ModerateDemented	NonDemented	VeryMildDemented
		Tahmin Edilen Etiketler			

Şekil 4.39: MyCNN Rmsprop Yüksek Ayarlı Eğitim Karşılaştırma Matrisi

Şekil 4.40: MyCNN Rmsprop Düşük Ayarlı Eğitim Karşılaştırma Matrisi

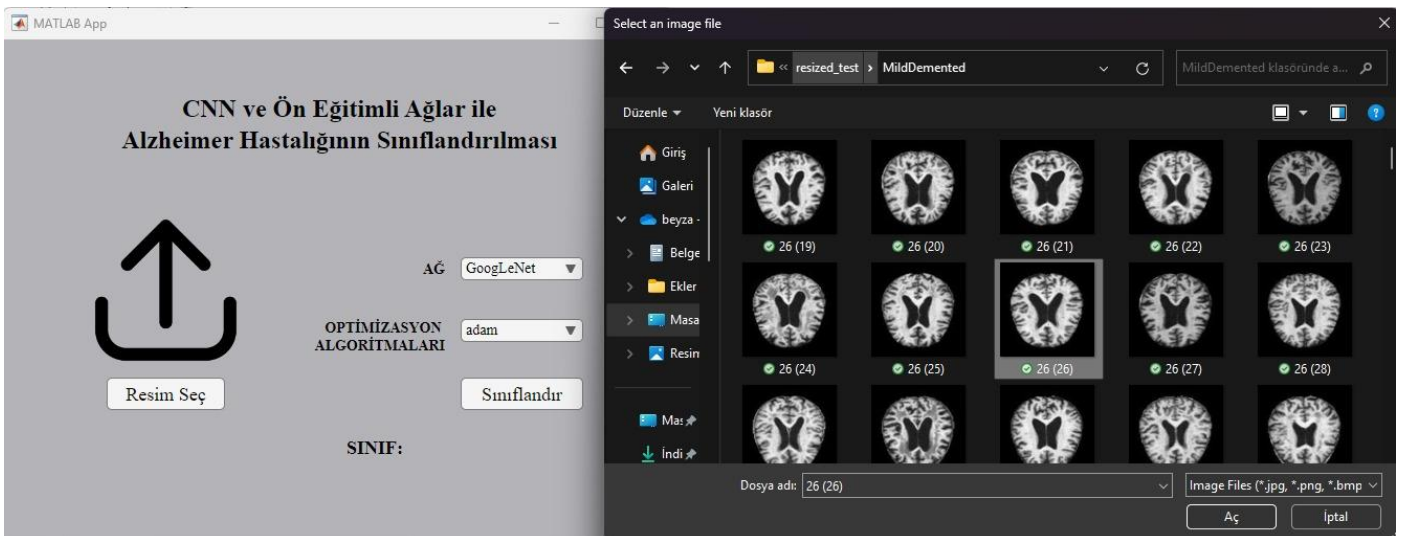
5. Uygulamanın Kullanışı

Uygulama ilk açıldığında başlangıç olarak tüm eğitilmiş ağırları bir değişkene yükler. Resim yükleme simgesine tıklandığında resim seçmek için bir dosya seçici açılır. Yüklenen resim ve açılır menüden seçilen ayarlara göre tahmin gerçekleştirilir ve sonuç ekranının alt kısmına yazılır.



Şekil 5.41: Uygulama Açılış Ekranı

Uygulamanın açılış ekranında sol kısımda resim yükleme alanı, sağ kısımda ağırların seçimleri ve bir sınıflandırma butonu yer almaktadır. Alt kısımda ise başlangıçta boş olan mesajların yazıldığı alan bulunmaktadır.



Şekil 5.42: Resim Seçme Ekranı



Şekil 5.43: Ağ Seçme Ekranı

Resme tıklandığında istenilen formatlarda dosya seçme ekranı açılmaktadır.



Seçilen dosya ekranının sol tarafında görünmektedir. Bu adımdan sonra tahmin için seçilen ağın parametreleri seçilir ve sınıflandır butonuna basıldığında alt kısımdaki mesaj alanında sınıflandırma sonucu görünmektedir.

6. Sonuç

Bu araştırma, farklı evrelerdeki Alzheimer MR görüntülerinin sınıflandırılması için derin öğrenme modellerinin uygulanmasını sağlamıştır. Derin öğrenme teknikleri, Alzheimer hastalığının erken teşhisinde önemli bir araç olma potansiyeline sahiptir. Bu çalışmanın bulguları, bu alandaki araştırmaların ve geliştirmelerin önemini vurgulamaktadır ve gelecekte daha etkili teşhis ve tedavi yöntemlerinin geliştirilmesine katkıda bulunabileceğini göstermektedir.

7. Referanslar

- [1] A. D. International, “World Alzheimer Report 2023: Reducing Dementia Risk: Never too early, never too late.” Sep. 21, 2023. Accessed: Apr. 30, 2024. [Online]. Available: <https://www.alzint.org/resource/world-alzheimer-report-2023/>
- [2] S. F. Javaid, C. Giebel, M. A. Khan, and M. J. Hashim, “Epidemiology of Alzheimer’s disease and other dementias: rising global burden and forecasted trends,” *F1000Research* 2021 10:425, vol. 10, p. 425, May 2021, doi: 10.12688/f1000research.50786.1.
- [3] S. Spasov, L. Passamonti, A. Duggento, P. Liò, and N. Toschi, “A parameter-efficient deep learning approach to predict conversion from mild cognitive impairment to Alzheimer’s disease,” *Neuroimage*, vol. 189, pp. 276–287, Apr. 2019, doi: 10.1016/J.NEUROIMAGE.2019.01.031.
- [4] J. P. Amezquita-Sanchez, N. Mammone, F. C. Morabito, S. Marino, and H. Adeli, “A novel methodology for automated differential diagnosis of mild cognitive impairment and the Alzheimer’s disease using EEG signals,” *J Neurosci Methods*, vol. 322, pp. 88–95, Jul. 2019, doi: 10.1016/J.JNEUMETH.2019.04.013.
- [5] M. N. Sabbagh *et al.*, “Early Detection of Mild Cognitive Impairment (MCI) in Primary Care,” *Journal of Prevention of Alzheimer’s Disease*, vol. 7, no. 3, pp. 165–170, Mar. 2020, doi: 10.14283/JPAD.2020.21/METRICS.
- [6] F. Er and D. Goularas, “Predicting the Prognosis of MCI Patients Using Longitudinal MRI Data,” *IEEE/ACM Trans Comput Biol Bioinform*, vol. 18, no. 3, pp. 1164–1173, May 2021, doi: 10.1109/TCBB.2020.3017872.
- [7] S. Afzal *et al.*, “Alzheimer Disease Detection Techniques and Methods: A Review,” *International Journal of Interactive Multimedia and Artificial Intelligence*, vol. 6, no. 7, pp. 26–38, 2021, doi: 10.9781/IJIMAI.2021.04.005.
- [8] P. Thakare and V. R. Pawar, “Alzheimer disease detection and tracking of Alzheimer patient,” *Proceedings of the International Conference on Inventive Computation Technologies, ICICT 2016*, vol. 1, Jul. 2016, doi: 10.1109/INVENTIVE.2016.7823286.
- [9] C. M. Clark *et al.*, “Biomarkers for Early Detection of Alzheimer Pathology,” *Neurosignals*, vol. 16, no. 1, pp. 11–18, Dec. 2007, doi: 10.1159/000109754.
- [10] U. R. Acharya *et al.*, “Automated Detection of Alzheimer’s Disease Using Brain MRI Images– A Study with Various Feature Extraction Techniques,” *J Med Syst*, vol. 43, no. 9, pp. 1–14, Sep. 2019, doi: 10.1007/S10916-019-1428-9/METRICS.
- [11] K. A. N. N. P. Gunawardena, R. N. Rajapakse, and N. D. Kodikara, “Applying convolutional neural networks for pre-detection of Alzheimer’s disease from structural MRI data,” *2017 24th International Conference on Mechatronics and Machine Vision in Practice, M2VIP 2017*, vol. 2017-December, pp. 1–7, Dec. 2017, doi: 10.1109/M2VIP.2017.8211486.
- [12] T. M. Ghazal *et al.*, “Alzheimer Disease Detection Empowered with Transfer Learning,” doi: 10.32604/cmc.2022.020866.
- [13] F. Er and D. Goularas, “Predicting the Prognosis of MCI Patients Using Longitudinal MRI Data,”

- IEEE/ACM Trans Comput Biol Bioinform*, vol. 18, no. 3, pp. 1164–1173, May 2021, doi: 10.1109/TCBB.2020.3017872.
- [14] S. H. Hojjati, A. Ebrahimzadeh, A. Khazaei, and A. Babajani-Feremi, “Predicting conversion from MCI to AD by integrating rs-fMRI and structural MRI,” *Comput Biol Med*, vol. 102, pp. 30–39, Nov. 2018, doi: 10.1016/J.COMPBIOMED.2018.09.004.
 - [15] N. Pradhan, S. Sagar, and A. S. Singh, “Analysis of MRI image data for Alzheimer disease detection using deep learning techniques,” *Multimed Tools Appl*, vol. 83, no. 6, pp. 17729–17752, Feb. 2024, doi: 10.1007/S11042-023-16256-2/METRICS.
 - [16] “Convolutional neural networks for Alzheimer’s disease detection on MRI images.” Accessed: Apr. 30, 2024. [Online]. Available: <https://www.spiedigitallibrary.org/journals/journal-of-medical-imaging/volume-8/issue-2/024503/Convolutional-neural-networks-for-Alzheimers-disease-detection-on-MRI-images/10.1117/1.JMI.8.2.024503.full>
 - [17] W. Feng *et al.*, “Automated MRI-Based Deep Learning Model for Detection of Alzheimer’s Disease Process,” <https://doi.org/10.1142/S012906572050032X>, vol. 30, no. 6, May 2020, doi: 10.1142/S012906572050032X.
 - [18] A. W. Salehi, P. Baglat, B. B. Sharma, G. Gupta, and A. Upadhyay, “A CNN Model: Earlier Diagnosis and Classification of Alzheimer Disease using MRI,” *Proceedings - International Conference on Smart Electronics and Communication, ICOSEC 2020*, pp. 156–161, Sep. 2020, doi: 10.1109/ICOSEC49089.2020.9215402.
 - [19] “Convolutional neural networks for Alzheimer’s disease detection on MRI images.” Accessed: May 01, 2024. [Online]. Available: <https://www.spiedigitallibrary.org/journals/journal-of-medical-imaging/volume-8/issue-2/024503/Convolutional-neural-networks-for-Alzheimers-disease-detection-on-MRI-images/10.1117/1.JMI.8.2.024503.full>
 - [20] S. Sarraf, G. Tofighi, and S. Org, “Classification of Alzheimer’s Disease Structural MRI Data by Deep Learning Convolutional Neural Networks,” Jul. 2016, Accessed: May 01, 2024. [Online]. Available: <https://arxiv.org/abs/1607.06583v2>
 - [21] H. Acharya, R. Mehta, and D. Kumar Singh, “Alzheimer Disease Classification Using Transfer Learning,” *Proceedings - 5th International Conference on Computing Methodologies and Communication, ICCMC 2021*, pp. 1503–1508, Apr. 2021, doi: 10.1109/ICCMC51019.2021.9418294.
 - [22] C. Szegedy *et al.*, “Going Deeper with Convolutions,” *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, vol. 07-12-June-2015, pp. 1–9, Sep. 2014, doi: 10.1109/CVPR.2015.7298594.
 - [23] A. G. Howard *et al.*, “MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications,” Apr. 2017, Accessed: May 02, 2024. [Online]. Available: <https://arxiv.org/abs/1704.04861v1>
 - [24] Q. Xiang, G. Zhang, X. Wang, J. Lai, R. Li, and Q. Hu, “Fruit image classification based on Mobilenetv2 with transfer learning technique,” *ACM International Conference Proceeding Series*, Oct. 2019, doi: 10.1145/3331453.3361658.
 - [25] R. Indraswari, R. Rokhana, and W. Herulambang, “Melanoma image classification based on MobileNetV2 network,” *Procedia Comput Sci*, vol. 197, pp. 198–207, Jan. 2022, doi: 10.1016/J.PROCS.2021.12.132.
 - [26] M. Akay *et al.*, “Deep Learning Classification of Systemic Sclerosis Skin Using the MobileNetV2 Model,” *IEEE Open J Eng Med Biol*, vol. 2, pp. 104–110, 2021, doi: 10.1109/OJEMB.2021.3066097.
 - [27] K. Dong, C. Zhou, Y. Ruan, and Y. Li, “MobileNetV2 Model for Image Classification,” *Proceedings - 2020 2nd International Conference on Information Technology and Computer Application, ITCA 2020*, pp. 476–480, Dec. 2020, doi: 10.1109/ITCA52113.2020.00106.